

Detecção de Falha de Motor em VANTs com Aprendizado de Máquina

Resumo de Resultados

Resumo

Este trabalho apresenta um sistema de detecção automática de falha de motor em voo para a aeronave não tripulada de asa fixa CarbonZ, com base em aprendizado de máquina não supervisionado. Dois modelos *Isolation Forest* foram treinados com trilhas de *features* distintas — grandezas físicas (`all_features`) e domínio da frequência (`fft_features`) — sobre 33 voos em formato ROS (~ 520 Hz). O modelo físico detectou 16/23 falhas com latência mediana de 3,15 s e precisão de 0,983; o modelo espectral detectou 15/23 falhas com latência mediana de 2,64 s, atuando como *precursor* da falha ao custo de mais alarmes falsos.

Palavras-chave: Detecção de Anomalia, VANT, Falha de Motor, *Isolation Forest*, FFT, *Isolation Forest*.

1 Introdução

Em voo autônomo, identificar a perda de tração com latência mínima viabiliza resposta de emergência eficaz (pouso de emergência ou autorrotação). O conjunto de dados conta com 33 voos registrados em formato ROS: 23 com falhas induzidas de motor e 10 voos normais, com dados de múltiplos sensores coletados a ~ 520 Hz [2].

2 Metodologia

A solução foi construída como um *pipeline* Kedro completo [4], da ingestão dos tópicos ROS (alinhamento temporal via `merge_asof`) ao treinamento. Duas trilhas paralelas de engenharia de *features* foram desenvolvidas: (i) `all_features` — grandezas físicas como energia específica, esforço de controle e razão de planeio, acrescidas de estatísticas em janelas deslizantes; (ii) `fft_features` — potência de pico, entropia espectral e razão de alta frequência dos sinais IMU e magnetômetro. As 20 melhores *features* foram selecionadas pelo d de Cohen [1]. O detector escolhido foi o *Isolation Forest* [3] com janelas deslizantes de 20 amostras, regime não supervisionado, adequado à escassez de exemplos rotulados de falha.

3 Resultados

A Tabela 1 apresenta as métricas de classificação calculadas com a função `classification_report` sobre o conjunto de teste (últimos 30% de cada voo, em ordem temporal), no nível de janela de 20 amostras.

Tabela 1: Métricas por modelo e classe (nível de janela de 20 amostras).

Modelo	Classe	Precisão	Recall	F1
<code>all_features</code>	Normal (0)	0,874	0,999	0,932
<code>all_features</code>	Falha (1)	0,983	0,184	0,310
<code>fft_features</code>	Normal (0)	0,856	0,955	0,903
<code>fft_features</code>	Falha (1)	0,402	0,158	0,227

O elevado *recall* da classe Normal no `all_features` (0,999) reflete o comportamento conservador do *Isolation Forest* configurado com `contamination=0,03`: apenas 53 das 93.289 janelas normais são classificadas como anomalia, correspondendo a uma taxa de falso positivo por janela de apenas 0,057%. Essa conservatividade se inverte na classe de falha — o *recall* de 0,184 indica que o modelo flagra somente as janelas onde os efeitos da falha já se manifestaram de forma inequívoca nas grandezas físicas. As janelas que ele detecta, porém, são quase todas reais: precisão de 0,983.

O `fft_features` apresenta comportamento distinto. Seu *recall* para a classe Normal é menor (0,955), o que se traduz em volume muito maior de alarmes falsos por janela — em alguns voos, centenas a mais de mil janelas são marcadas como anomalia *antes* do momento oficial da falha. Esse padrão não é ruído aleatório: ele sugere que o modelo captura a degradação espectral progressiva do motor como precursor físico da falha, e não apenas suas consequências. O custo operacional é a menor confiabilidade por alarme (precisão de 0,402 na classe de falha).

A Tabela 2 resume os indicadores de desempenho no nível de voo, e a Tabela 3 apresenta as matrizes de confusão correspondentes. Um voo é classificado como TP se o modelo emitiu ao menos um alarme durante o intervalo de falha, FN caso contrário; voos normais com ao menos um alarme figuram como FP.

Tabela 2: Resumo de desempenho no nível de voo.

Indicador	<code>all_features</code>	<code>fft_features</code>
Falhas detectadas	16/23 (69,6 %)	15/23 (65,2 %)
Voos normais com FP	6/10 (60,0 %)	3/10 (30,0 %)
Latência mediana	3,15 s	2,64 s
Latência média	6,72 s	4,57 s

Tabela 3: Matrizes de confusão — nível de voo.

<code>all_features</code>			<code>fft_features</code>		
	Alarme	Silêncio		Alarme	Silêncio
Com falha	TP = 16	FN = 7	Com falha	TP = 15	FN = 8
Sem falha	FP = 6	TN = 4	Sem falha	FP = 3	TN = 7

4 Discussão

Os dois modelos capturam fenômenos físicos distintos com perfis de erro opostos. O `all_features` reage às *consequências* da falha — queda de energia específica, divergência entre *throttle* e velocidade, acúmulo de erros de controle — sendo altamente conservador: cada alarme tem 98,3% de chance de ser genuíno, mas o modelo silencia quando os efeitos ainda não se consolidaram, o que explica as 7 falhas perdidas. Em contraste, o `fft_features` detecta a assinatura espectral da degradação *antes* do momento oficial da falha, capturando o caos vibracional e a perda de pico de potência do motor. Esse comportamento de *precursor* é evidenciado pelas centenas a milhares de janelas de alarme que antecedem a falha em alguns voos (e.g., 1.455 janelas no voo 2018-10-18 #3), mas compromete a precisão por alarme (0,402) e inviabiliza seu uso isolado em operações com custo operacional elevado por falso positivo.

Cabe destacar que o conjunto de dados é pequeno (33 voos) e o hiperparâmetro `contamination=0,03` foi escolhido de forma conservadora; um ajuste fino por validação cruzada temporal poderia melhorar o *recall* da classe de falha sem sacrificar a especificidade. Ainda assim, mesmo na configuração atual, um sistema em cascata de dois estágios poderia ser útil: o `fft_features` atuaria como detector precoce de baixo limiar e, ao emitir alarme, iniciaria uma janela de confirmação; o `all_features` verificaria se os efeitos físicos se manifestaram dentro dessa janela antes de acionar a resposta de emergência. Essa arquitetura preservaria a latência reduzida do modelo espectral e a especificidade elevada do modelo físico. Um *ensemble* com votação ponderada é uma alternativa mais simples, porém com menor interpretabilidade.

5 Conclusão

O trabalho demonstrou a viabilidade de detectar falha de motor em VANTs de asa fixa com latência mediana inferior a 4s usando aprendizado não supervisionado sobre *features* físicas e espectrais. O `all_features` é o mais confiável operacionalmente (precisão 0,983, 69,6% de detecção); o `fft_features` é mais veloz e atua como precursor (latência mediana 2,64s, apenas 30% de falsos positivos em voos normais). Nenhum modelo isolado satisfaz simultaneamente os requisitos de baixa latência e alta especificidade. Como trabalho futuro, recomenda-se implementar a arquitetura em cascata proposta, ajustar o `contamination` por validação temporal e ampliar o conjunto de dados com novos voos para cobrir cenários de falha não representados.

Referências

- [1] Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, 2 edition, 1988.
- [2] Azarakhsh Keipour, Mohammadreza Mousaei, and Sebastian Scherer. Automatic real-time anomaly detection for autonomous aerial vehicles. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, pages 5679–5685, 2019.
- [3] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. Isolation forest. In *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, pages 413–422, 2008.

- [4] QuantumBlack, AI by McKinsey. Kedro: A python framework for reproducible, maintainable and modular data science code. <https://github.com/kedro-org/kedro>, 2020. Acesso em: abr. 2025.