

Detecção de Falha de Motor em VANTs com Aprendizado de Máquina

1 Ideia central

O projeto desenvolve um sistema de detecção automática de falha de motor em voo para uma aeronave não tripulada de asa fixa (CarbonZ). A motivação é crítica: em voo autônomo, identificar o momento exato da perda de tração com latência mínima é o que viabiliza uma resposta de emergência eficaz — seja um pouso de emergência ou um comando de autorrotação. O conjunto de dados conta com 33 voos registrados em formato ROS, sendo 23 com falhas induzidas de motor e 10 voos normais, com dados de múltiplos sensores coletados a ~ 520 Hz.

2 Metodologia

A solução foi construída como um *pipeline* Kedro completo, cobrindo desde a ingestão dos tópicos ROS (com alinhamento temporal entre sensores via `merge_asof`) até o treinamento dos modelos. Foram desenvolvidas duas trilhas paralelas de engenharia de *features*: a primeira (`all_features`) extrai grandezas físicas como energia específica, esforço de controle e razão de planeio, além de estatísticas em janelas deslizantes (média, desvio-padrão e inclinação linear); a segunda (`fft_features`) opera no domínio da frequência, extraindo potência de pico, entropia espectral e razão de alta frequência dos sinais do IMU e magnetômetro. A seleção das 20 melhores *features* foi feita pelo d de Cohen, que mede a separabilidade entre as distribuições em voo normal e em falha sem o viés de autocorrelação temporal que afetaria a importância de *Random Forest*. O modelo escolhido foi *Isolation Forest*, treinado com janelas deslizantes de 20 amostras por ponto, no regime não supervisionado — adequado à escassez de exemplos rotulados de falha.

3 Resultados e *trade-off* entre os modelos

Os dois modelos têm perfis de erro opostos, o que revela que capturam fenômenos físicos distintos. O modelo `all_features` detectou 16 das 23 falhas (69,6%) com latência mediana de 3,15 s, reagindo às *consequências* da falha: queda de energia, divergência entre *throttle* e velocidade, acúmulo de erros de controle. Seu ponto fraco é a baixa revocação na classe de falha (18,4%) — ele é conservador e tende a silenciar em casos ambíguos.

O modelo `fft_features` detectou 15 falhas (65,2%) com latência mediana de 2,64 s, mas a maioria das detecções ocorreu *antes* do momento oficial da falha — o que sugere que ele captura a assinatura de vibração e caos espectral da degradação do motor como *precursor*, não como consequência. O custo é alto: 60% dos voos normais geraram ao menos um alarme falso no `all_features`, contra 30% no `fft_features`.

Em termos de aplicação, o `all_features` é preferível quando a confiabilidade operacional importa mais — cada alarme tem alta probabilidade de ser real. Já o `fft_features` é mais adequado em contextos de detecção precoce tolerantes a falsos positivos, por exemplo como primeiro estágio de um sistema em cascata onde sua detecção antecipada dispara o `all_features` como confirmatório. Um *ensemble* com votação ponderada pode combinar a sensibilidade espectral do FFT com a especificidade física do `all_features`.

4 Métricas por modelo e classe (nível de janela)

A Tabela 1 apresenta as métricas de classificação calculadas pela função `classification_report` do scikit-learn sobre o conjunto de teste (últimos 30% de cada voo, em ordem temporal). O elevado *recall* da classe 0 (Normal) no modelo `all_features` (0,999) reflete o comportamento conservador do *Isolation Forest* configurado com `contamination=0,03`: apenas 53 das 93.289 janelas normais são erroneamente classificadas como anomalia (taxa de falso positivo por janela de 0,057%).

Tabela 1: Métricas de classificação por modelo e classe (nível de janela de 20 amostras).

Modelo	Classe	Precisão	Recall	F1
<code>all_features</code>	Normal (0)	0,874	0,999	0,932
<code>all_features</code>	Falha (1)	0,983	0,184	0,310
<code>fft_features</code>	Normal (0)	0,856	0,955	0,903
<code>fft_features</code>	Falha (1)	0,402	0,158	0,227

5 Matrizes de confusão — nível de voo

Cada voo é classificado como um único evento: se o modelo emitiu alarme durante o intervalo de falha, o voo é TP; se nunca emitiu (ou só emitiu antes da janela de falha), é FN. Voos sem falha que geraram ao menos um alarme são FP; os demais, TN.

5.1 all_features

Falhas detectadas: 16/23 Falhas perdidas: 7/23 Lat. média: 6,72 s Lat. mediana: 3,15 s

Tabela 2: Matriz de confusão (nível de voo) — all_features.

	Alarme (positivo)	Silêncio (negativo)
Real: com falha	TP = 16	FN = 7
Real: sem falha	FP = 6	TN = 4

Tabela 3: Detalhe por voo com falha — all_features.

Voo	Falha (s)	Detec. (s)	Lat. (s)	Resultado	FP antes
2018-07-18 #1	115,3	—	—	FN	0
2018-07-18 #2	72,4	—	—	FN	0
2018-07-18 EMR	115,6	117,6	1,92	TP	0
2018-07-18 EMR2	113,1	115,8	2,72	TP	0
2018-07-30 EMR	122,2	133,1	10,98	TP	0
2018-07-30 #1	115,8	—	—	FN	0
2018-07-30 #2	90,7	—	—	FP antes	126
2018-07-30 EMR2	116,2	129,1	12,91	TP	0
2018-07-30 EMR3	86,7	94,0	7,34	TP	0
2018-07-30 EMR4	132,5	135,4	2,92	TP	0
2018-07-30 EMR5	89,4	100,5	11,16	TP	0
2018-09-11 #1	102,6	103,3	0,72	TP	0
2018-09-11 #2	103,9	—	—	FN	0
2018-09-11 #3	48,9	59,5	10,62	TP	0
2018-10-05 #1	48,2	64,2	16,00	TP	0
2018-10-05 #2	99,1	101,7	2,58	TP	0
2018-10-05 #3	75,2	91,2	15,99	TP	0
2018-10-18 #1	103,2	106,0	2,76	TP	0
2018-10-18 #2	110,1	113,1	3,00	TP	0
2018-10-18 #3	99,4	—	—	FN	0
2018-10-18 #4	97,3	—	—	FN	0

(continua na próxima página)

(continuação da Tabela 3)

Voo	Falha (s)	Detec. (s)	Lat. (s)	Resultado	FP antes
2018-10-18 #5	100,3	103,6	3,29	TP	0
2018-10-18 #6	101,6	104,2	2,66		53

Tabela 4: Detalhe por voo sem falha — all_features.

Voo	Alarmes falsos (janelas)	Resultado
2018-07-18 sem-falha	0	TN
2018-07-30 sem-falha	4	FP
2018-09-11 #1 sem-falha	72	FP
2018-09-11 #2 sem-falha	0	TN
2018-09-11 #3 sem-falha	162	FP
2018-10-05 #1 sem-falha	525	FP
2018-10-05 #2 sem-falha	64	FP
2018-10-05 #3 sem-falha	57	FP
2018-10-05 #4 sem-falha	0	TN
2018-10-18 sem-falha	0	TN

5.2 `fft_features`

Falhas detectadas: 15/23 Falhas perdidas: 8/23 Lat. média: 4,57 s Lat. mediana: 2,64 s

Tabela 5: Matriz de confusão (nível de voo) — `fft_features`.

	Alarme (positivo)	Silêncio (negativo)
Real: com falha	TP = 15	FN = 8
Real: sem falha	FP = 3	TN = 7

Tabela 6: Detalhe por voo com falha — `fft_features`.

Voo	Falha (s)	Detec. (s)	Lat. (s)	Resultado	FP antes
2018-07-18 #1	115,3	—	—	FN	69
2018-07-18 #2	72,4	—	—	FN	264
2018-07-18 EMR	115,6	117,8	2,17	TP	755
2018-07-18 EMR2	113,1	115,9	2,85	TP	0
2018-07-30 EMR	122,2	127,2	5,07	TP	380
2018-07-30 #1	115,8	130,4	14,64	TP	543
2018-07-30 #2	90,7	—	—	FN	220
2018-07-30 EMR2	116,2	—	—	FN	0
2018-07-30 EMR3	86,7	89,5	2,80	TP	0
2018-07-30 EMR4	132,5	154,5	21,99	TP	74
2018-07-30 EMR5	89,4	98,3	8,97	TP	258
2018-09-11 #1	102,6	104,0	1,41	TP	57
2018-09-11 #2	103,9	—	—	FN	26
2018-09-11 #3	48,9	—	—	FN	35
2018-10-05 #1	48,2	48,2	0,04	TP	0
2018-10-05 #2	99,1	99,3	0,19	TP	26
2018-10-05 #3	75,2	—	—	FN	93
2018-10-18 #1	103,2	105,9	2,64	TP	320
2018-10-18 #2	110,1	—	—	FN	579
2018-10-18 #3	99,4	99,7	0,27	TP	1455
2018-10-18 #4	97,3	100,1	2,80	TP	75

(continua na próxima página)

(continuação da Tabela 6)

Voo	Falha (s)	Detec. (s)	Lat. (s)	Resultado	FP antes
2018-10-18 #5	100,3	100,7	0,39	TP	654
2018-10-18 #6	101,6	103,8	2,25		693

Tabela 7: Detalhe por voo sem falha — `fft_features`.

Voo	Alarmes falsos (janelas)	Resultado
2018-07-18 sem-falha	0	TN
2018-07-30 sem-falha	184	FP
2018-09-11 #1 sem-falha	0	TN
2018-09-11 #2 sem-falha	278	FP
2018-09-11 #3 sem-falha	0	TN
2018-10-05 #1 sem-falha	0	TN
2018-10-05 #2 sem-falha	0	TN
2018-10-05 #3 sem-falha	332	FP
2018-10-05 #4 sem-falha	0	TN
2018-10-18 sem-falha	0	TN