

Detecção de Falha de Motor em VANTs com Aprendizado de Máquina

Ideia central

O projeto desenvolve um sistema de detecção automática de falha de motor em voo para uma aeronave não tripulada de asa fixa (CarbonZ). A motivação é crítica: em voo autônomo, identificar o momento exato da perda de tração com latência mínima é o que viabiliza uma resposta de emergência eficaz — seja um pouso de emergência ou um comando de autorrotação. O conjunto de dados conta com 33 voos registrados em formato ROS, sendo 23 com falhas induzidas de motor e 10 voos normais, com dados de múltiplos sensores coletados a ~520 Hz.

Como foi feito

A solução foi construída como um pipeline Kedro completo, cobrindo desde a ingestão dos tópicos ROS (com alinhamento temporal entre sensores via `merge_asof`) até o treinamento de modelos. Foram desenvolvidas duas trilhas paralelas de engenharia de features: a primeira (`all_features`) extrai grandezas físicas como energia específica, esforço de controle e razão de planeio, além de estatísticas em janelas deslizantes (média, desvio e inclinação linear); a segunda (`fft_features`) opera no domínio da frequência, extraíndo potência de pico, entropia espectral e razão de alta frequência dos sinais do IMU e magnetômetro. A seleção das 20 melhores features foi feita pelo `d` de Cohen, que mede a separabilidade entre as distribuições em voo normal e em falha sem o viés de autocorrelação temporal que afetaria a importância de Random Forest. O modelo escolhido foi Isolation Forest, treinado com janelas deslizantes de 20 amostras por ponto, no regime não supervisionado — adequado à escassez de exemplos rotulados de falha.

Resultados e trade-off entre os modelos

Os dois modelos têm perfis de erro opostos, o que revela que capturam fenômenos físicos distintos. O modelo `all_features` detectou 16 das 23 falhas (69,6%) com latência mediana de 3,15 s, reagindo às consequências da falha: queda de energia, divergência entre throttle e velocidade, acúmulo de erros de controle. Seu ponto fraco é a baixa revocação na classe de falha (18,4%) — ele é conservador e tende a silenciar em casos ambíguos. Já o modelo `fft_features` detectou 15 falhas (65,2%) com latência mediana de 2,64 s, mas 12 dessas 15 detecções ocorreram antes do momento oficial da falha — o que sugere que ele captura a assinatura de vibração e caos espectral da degradação do motor como precursor, não como consequência. O custo é alto: 60% dos voos normais geraram ao menos um alarme falso no `all_features`, contra 30% no `fft_features`. Em termos de aplicação, o `all_features` é preferível quando a confiabilidade operacional importa mais — cada alarme dele tem alta probabilidade de ser real. Já o `fft_features` seria mais adequado em contexto de detecção precoce tolerante a falsos positivos — por exemplo, como primeiro estágio de um sistema em cascata, onde sua

Detecção de Falha de Motor em VANTs com Aprendizado de Máquina

detecção antecipada dispararia o all_features como confirmatório. Um ensemble com votação ponderada pode combinar a sensibilidade espectral do FFT com a especificidade física do all_features.

Métricas por modelo e classe (nível de janela)

Modelo	Classe	Precisão	Recall	F1
all_features	Normal (0)	0.874	0.999	0.932
all_features	Falha (1)	0.983	0.184	0.310
fft_features	Normal (0)	0.856	0.955	0.903
fft_features	Falha (1)	0.402	0.158	0.227

Matrizes de Confusão — nível de voo (notebooks 04)

Cada voo é classificado como um único evento: se o modelo emitiu alarme durante o intervalo de falha, o voo é TP; se nunca emitiu (ou só emitiu antes da falha), é FN. Voos sem falha que geraram ao menos um alarme são FP; os demais, TN.

Modelo: all_features

Falhas detectadas: 16/23 | Falhas perdidas: 7/23 | Lat. média: 6.72 s | Lat. mediana: 3.15 s

	Alarme (positivo)	Silêncio (negativo)
Real: com falha	TP = 16	FN = 7
Real: sem falha	FP = 6	TN = 4

Voos COM falha (23 voos)

Voo (data/índice)	Falha (s)	Detect. (s)	Lat. (s)	Resultado	FP antes
2018-07-18 #1	115.3	—	—	FN	0
2018-07-18 #2	72.4	—	—	FN	0
2018-07-18 EMR	115.6	117.6	1.92	TP	0
2018-07-18 EMR2	113.1	115.8	2.72	TP	0
2018-07-30 EMR	122.2	133.1	10.98	TP	0
2018-07-30 #1	115.8	—	—	FN	0
2018-07-30 #2	90.7	—	—	FP antes	126
2018-07-30 EMR2	116.2	129.1	12.91	TP	0
2018-07-30 EMR3	86.7	94.0	7.34	TP	0
2018-07-30 EMR4	132.5	135.4	2.92	TP	0
2018-07-30 EMR5	89.4	100.5	11.16	TP	0
2018-09-11 #1	102.6	103.3	0.72	TP	0
2018-09-11 #2	103.9	—	—	FN	0
2018-09-11 #3	48.9	59.5	10.62	TP	0
2018-10-05 #1	48.2	64.2	16.00	TP	0
2018-10-05 #2	99.1	101.7	2.58	TP	0
2018-10-05 #3	75.2	91.2	15.99	TP	0
2018-10-18 #1	103.2	106.0	2.76	TP	0
2018-10-18 #2	110.1	113.1	3.00	TP	0
2018-10-18 #3	99.4	—	—	FN	0
2018-10-18 #4	97.3	—	—	FN	0
2018-10-18 #5	100.3	103.6	3.29	TP	0
2018-10-18 #6	101.6	104.2	2.66	TP	53

Voos SEM falha (10 voos)

Detecção de Falha de Motor em VANTs com Aprendizado de Máquina

Voo (data/índice)	Alarmes falsos (janelas)	Resultado
2018-07-18 sem-falha	0	TN
2018-07-30 sem-falha	4	FP
2018-09-11 #1 sem-falha	72	FP
2018-09-11 #2 sem-falha	0	TN
2018-09-11 #3 sem-falha	162	FP
2018-10-05 #1 sem-falha	525	FP
2018-10-05 #2 sem-falha	64	FP
2018-10-05 #3 sem-falha	57	FP
2018-10-05 #4 sem-falha	0	TN
2018-10-18 sem-falha	0	TN

Detecção de Falha de Motor em VANTs com Aprendizado de Máquina

Modelo: `fft_features`

Falhas detectadas: 15/23 | Falhas perdidas: 8/23 | Lat. média: 4.57 s | Lat. mediana: 2.64 s

	Alarme (positivo)	Silêncio (negativo)
Real: com falha	TP = 15	FN = 8
Real: sem falha	FP = 3	TN = 7

Voos COM falha (23 voos)

Voo (data/índice)	Falha (s)	Detect. (s)	Lat. (s)	Resultado	FP antes
2018-07-18 #1	115.3	—	—	FN	69
2018-07-18 #2	72.4	—	—	FN	264
2018-07-18 EMR	115.6	117.8	2.17	TP	755
2018-07-18 EMR2	113.1	115.9	2.85	TP	0
2018-07-30 EMR	122.2	127.2	5.07	TP	380
2018-07-30 #1	115.8	130.4	14.64	TP	543
2018-07-30 #2	90.7	—	—	FN	220
2018-07-30 EMR2	116.2	—	—	FN	0
2018-07-30 EMR3	86.7	89.5	2.80	TP	0
2018-07-30 EMR4	132.5	154.5	21.99	TP	74
2018-07-30 EMR5	89.4	98.3	8.97	TP	258
2018-09-11 #1	102.6	104.0	1.41	TP	57
2018-09-11 #2	103.9	—	—	FN	26
2018-09-11 #3	48.9	—	—	FN	35
2018-10-05 #1	48.2	48.2	0.04	TP	0
2018-10-05 #2	99.1	99.3	0.19	TP	26
2018-10-05 #3	75.2	—	—	FN	93
2018-10-18 #1	103.2	105.9	2.64	TP	320
2018-10-18 #2	110.1	—	—	FN	579
2018-10-18 #3	99.4	99.7	0.27	TP	1455
2018-10-18 #4	97.3	100.1	2.80	TP	75
2018-10-18 #5	100.3	100.7	0.39	TP	654
2018-10-18 #6	101.6	103.8	2.25	TP	693

Voos SEM falha (10 voos)

Voo (data/índice)	Alarmes falsos (janelas)	Resultado
2018-07-18 sem-falha	0	TN
2018-07-30 sem-falha	184	FP
2018-09-11 #1 sem-falha	0	TN

Detecção de Falha de Motor em VANTs com Aprendizado de Máquina

2018-09-11 #2 sem-falha	278	FP
2018-09-11 #3 sem-falha	0	TN
2018-10-05 #1 sem-falha	0	TN
2018-10-05 #2 sem-falha	0	TN
2018-10-05 #3 sem-falha	332	FP
2018-10-05 #4 sem-falha	0	TN
2018-10-18 sem-falha	0	TN